



《多模态大模型原理与应用》结题报告

题目：文档理解与多模态 GraphRAG 检索问答系统结题报告

姓名 丁子睿、梁力航、李俊璋

学号 23336058、23336128、23336113

院系 计算机学院

专业 计算机科学与技术

指导教师 刘阳

2026 年 6 月 16 日

摘 要

传统文本检索增强生成 (RAG) 在处理图文混排、跨页引用和结构复杂的长文档时, 容易丢失图表、版面和跨页关系等关键信息, 导致答案缺乏稳定证据支撑。针对这一问题, 本文设计并实现了 DocRAG——一个多模态 GraphRAG 文档问答系统, 采用“FAISS 向量索引 + NetworkX 异构文档图 + 视觉语言模型”的技术路线, 完成从 PDF 入库、页面结构化解析、向量索引与知识图谱构建到多模态检索问答的完整链路。系统使用 PyMuPDF 渲染页面图像, 调用 Qwen3-VL-8B-Instruct 抽取文本、表格、图表、结论、关键词和关系, 并在问答阶段融合向量召回、图谱邻域扩展和页面图像证据生成答案。

实验方面, 本文基于 pdfQA 中的 12 篇 ESG 报告构建了 120 道覆盖文本定位、表格问答、图表理解、跨页延续、多跳关系和引用追踪的问题集, 并设计五组消融实验评估各组件作用。结果表明, 完整系统在证据页命中和答案生成稳定性上表现最好, FAISS 语义召回是核心基础, 知识图谱和页面图像进一步提升了证据定位与视觉推理能力。token 成本实验显示, DocRAG 仅发送检索后的相关页面和文本证据, 可将单次问答输入从约 5–8 万等效 token 降至约 3000–5000 等效 token, 输入 token 节省约 94%, 显著降低了长文档多轮问答和批量评测的调用成本。

关键词: 文档理解, 检索增强生成, GraphRAG, 多模态问答, 视觉语言模型, 知识图谱

目 录

1 绪论 1

1.1 研究背景与意义 1

1.2 研究目标与内容 2

1.3 论文组织结构 2

2 相关工作 4

2.1 检索增强生成 (RAG) 4

2.2 图增强检索与 GraphRAG 4

2.3 多模态文档理解与问答 4

2.4 视觉语言模型 5

3 系统设计与实现 7

3.1 总体架构 7

3.2 文档解析与结构化抽取 8

3.3 知识图谱构建 8

3.4 GraphRAG 问答流程 9

3.5 前后端交互设计 9

4 实验设计与结果分析 11

4.1 实验设置 11

4.2 实验结果 12

4.3 Token 成本分析 14

4.4 错误分析 15

4.5 人工评分交叉验证 16

4.6 实验小结 18

5 总结与展望 19

5.1 主要工作总结 19

5.2 局限性与未来展望 20

参考文献 21

致谢 22

1 绪论

1.1 研究背景与意义

随着大语言模型（Large Language Models, LLMs）的飞速发展，其在自然语言理解与生成任务上展现出卓越的能力。然而，纯参数化的 LLM 面临知识时效性不足、事实性偏差（幻觉）以及难以追溯推理依据等问题。检索增强生成（Retrieval-Augmented Generation, RAG）技术通过在生成回答前从外部知识库检索相关证据，将参数化知识与非参数化外部知识相结合，有效缓解了上述问题^[1]。RAG 的核心价值在于提升知识密集型任务的事实性、可更新性和证据可追踪性，已在企业知识问答、学术文献分析、法律文书检索等场景得到广泛应用。

然而，真实世界中的文档远非纯文本集合。学术论文、企业财报、技术手册、合同文书和教学课件等文档通常同时包含正文、公式、表格、图表、图像、图注、脚注、跨页段落和图表引用等多种信息形态。传统文本 RAG 主要依赖 OCR 或 PDF 文本抽取后的纯文本向量相似度匹配，在处理这类图文混排的复杂文档时面临三个根本性挑战：

- (1) **视觉信息丢失**：图表趋势、版面结构、颜色标记、坐标轴和表格边界等视觉信息很难被纯文本准确保留。许多关键语义（如折线图的趋势方向、柱状图的对比关系、流程图的步骤先后）天然依赖视觉表达，仅靠文本描述难以完整捕捉。
- (2) **结构关系不足**：同一页内的图文对应关系、跨页段落的延续关系、图号与结论之间的支撑关系、关键词与内容片段的锚定关系等，很难仅通过向量相似度稳定表达。真实文档中的重要信息往往不是线性排列，而是通过复杂的引用关系相互关联。
- (3) **证据链不可解释**：向量检索擅长找到与查询语义相似的孤立文本片段，但不擅长回答“某结论由哪些图表和实验支撑”这类多跳推理问题。用户难以追溯答案的证据来源和推理路径。

GraphRAG 技术通过在传统 RAG 的基础上引入图结构，为解决上述问题提供了新的思路。GraphRAG 将知识库中的文本片段、实体、概念、关系和事件组织为知识图谱，使检索不仅依赖语义相似度，还能沿图谱中的关系边进行多跳扩展^[2]。对于文档问答而言，图结构可以将页面、图表、表格、段落、关键词和结论等异质元素统一组织到同一证据空间中，通过显式的关系边捕获跨页延续、图文支撑和多跳推理路径。

与此同时，视觉语言模型（Vision-Language Models, VLMs）的快速发展为多

模态文档理解提供了强大的技术基础。以 Qwen3-VL 系列为代表的视觉语言模型能够直接接收页面图像和文本提示，完成 OCR 识别、版面理解、图表描述、结构化抽取和视觉问答等任务^[3]。这为构建端到端的多模态文档问答系统提供了便利：不再需要组合 OCR 引擎、版面分析器、表格识别器等多个独立模块，而是由一个统一的 VLM 完成多模态文档理解的各项子任务。

1.2 研究目标与内容

本项目面向中山大学 2025–2026 春季学期“多模态大模型原理与应用”课程题目 3“文档理解 + 多模态检索问答系统”，目标是设计并实现一个能够处理 PDF、扫描文档、论文页面和演示文稿截图的多模态 GraphRAG 文档问答系统。

本研究的核心问题是：对于图文混排、跨页引用和结构复杂的长文档，如何把页面视觉信息、文本语义片段和知识图谱关系融合到同一条检索问答链路中，使回答既能利用多模态证据，又能给出可追溯的页码、节点和关系依据？

围绕这一核心问题，本项目的具体研究内容包括：

- (1) **多模态文档解析与结构化**：设计基于 VLM 的页面图像结构化抽取流水线，从文档页面中同时提取文本块、表格、图表描述、结论、关键词和语义关系，生成结构化的多模态文档表示。
- (2) **异构图谱构建**：设计面向文档问答的异构文档图结构，将文本、表格、图表、结论、关键词等内容节点通过同页边、关键词边、跨页延续边和语义关系边组织为统一的知识图谱。
- (3) **GraphRAG 检索与生成**：设计融合向量检索、图谱邻域扩展和社区级全局补充的多阶段检索策略，以及将文本证据、关系路径和页面图像融合为多模态上下文的答案生成方法。
- (4) **系统实现与前端可视化**：实现完整的端到端系统原型，包括文档入库、知识库管理、在线问答、图谱可视化等核心功能，提供可交互的 Web 界面。
- (5) **实验评测与成本分析**：构建测试集，设计多组消融实验，系统性评估向量检索、知识图谱和多模态证据各组件对问答性能的贡献；同时比较 DocRAG 检索式问答与整篇 PDF 直接上传式问答的 token 消耗，分析系统在长文档场景下的调用成本优势。

1.3 论文组织结构

本文其余章节的组织如下：

- **第二章-相关工作**：系统回顾 RAG、GraphRAG、多模态文档理解和视觉语言

模型等领域的研究现状，分析现有工作的优势与不足，明确本项目的技术定位。

- **第三章-系统设计与实现**：详细阐述系统的总体架构、核心模块设计、关键技术实现细节，包括文档解析流水线、图谱构建算法、GraphRAG 检索与生成策略、后端 API 和前端界面。
- **第四章-实验设计与结果分析**：介绍测试集、评测指标和消融实验设置，报告整体性能、消融结果和不同题型下的表现差异；进一步分析 token 调用成本、典型错误案例和人工评分交叉验证结果，综合讨论系统各组件对回答质量、证据命中和调用成本的影响。
- **第五章-总结与展望**：总结本文的主要工作和贡献，分析系统的局限性，展望未来改进方向。

2 相关工作

本章从检索增强生成、图增强检索、多模态文档理解和视觉语言模型四个方面梳理相关研究。

2.1 检索增强生成 (RAG)

Lewis 等人在 NeurIPS 2020 提出的 RAG 框架证明了“参数知识 + 非参数知识”的组合方式能显著提升知识密集型 NLP 任务的准确性和可追溯性^[1]。典型 RAG 流程将文档切分为文本块并存入 FAISS 等向量数据库^[4]，查询时通过语义相似度检索相关片段交由生成模型作答。然而标准 RAG 将文档处理为独立文本片段，难以处理跨段落、跨页面、多实体关联和证据链推理的复杂问题；在图文混排场景中，PDF 文本抽取或 OCR 阶段还易丢失版面信息、图像语义和表格结构。模块化 RAG 和自反思 RAG 等改进方案主要在文本检索框架内优化，未从根本上解决文档结构关系和多模态信息融合问题。

2.2 图增强检索与 GraphRAG

GraphRAG 引入图结构来组织内容，使检索能沿图关系扩展证据。Edge 等人提出的 GraphRAG 框架将文档构造成实体知识图谱并生成社区摘要，同时支持围绕实体的局部搜索 (Local Search) 和基于社区总结的全局搜索 (Global Search)^[2]。微软官方实现进一步提供了基于 Leiden 算法的层级社区检测和 map-reduce 式全局回答流程^[5]。Bu 等人在 ACL 2025 提出了 Query-Driven Multimodal GraphRAG，强调根据查询语义动态构建局部图以提升跨模态推理^[6]。

现有 GraphRAG 工作主要面向大规模文本语料，构建流程计算成本较高，且对文档页面中的图表、表格和视觉布局等多模态信息利用不足。本项目的路线有所不同：直接从页面图像出发，使用 VLM 进行文本/表格/图表/关键词/关系的一体化抽取，构建轻量异构文档图，在查询时综合使用向量检索、图谱邻域扩展和社区补充，是一种更适合课程项目场景的多模态 GraphRAG 实现。

2.3 多模态文档理解与问答

DocVQA 数据集包含 12,000 余张文档图像和 50,000 余个问题，要求模型从文档图像中阅读文字、理解版面结构并给出抽取式答案^[7]。ChartQA 聚焦图表问答，

涉及柱状图、折线图、趋势比较和简单算术推理^[8]。这些基准揭示了文档问答的关键特征：视觉布局、表格边界、图表形态和图文对应关系本身就是语义的一部分。

与上述更偏单页图像或特定图表任务的基准相比，pdfQA 更接近本文关注的完整 PDF 问答场景^[2]。该基准面向真实和合成 PDF 文档，保留了文档级结构、页面顺序、表格、图表、扫描页和复杂版面等信息，并覆盖金融报告、科研论文、杂志、合同和手册等多种文档类型。由于本文系统需要处理多页 ESG 报告中的跨页证据、图表说明和表格信息，因此实验部分选择从 pdfQA 集中抽取报告，并在此基础上构建覆盖文本定位、表格问答、图表理解、跨页延续、多跳关系和引用追踪的自建测试集。

在多模态文档检索方面，ColPali 从页面图像直接生成多向量表示并使用 late interaction 检索，表明页面图像本身可作为检索对象^[9]。MMDocRAG 基准进一步强调长文档 RAG 需要选择并整合文本、表格、图像等多模态证据^[10]。这些工作启示我们：文档问答系统应保留页面原图、图表描述、bbox 等信息，同时关注证据引用的准确性和完整性。

2.4 视觉语言模型

视觉语言模型（Vision-Language Model, VLM）通过将图像编码器与大语言模型结合，使模型能够在同一语义空间中理解视觉内容和自然语言指令。LLaVA、MiniGPT-4 等工作利用视觉指令微调，使模型具备较强的图像描述、视觉问答和跨模态推理能力^[11-12]。在文档理解场景中，VLM 的价值不仅体现在识别页面中的文字，还体现在理解版面结构、表格行列关系、图表趋势、图文对应关系以及跨区域信息组合。相比将 PDF 先拆分为 OCR、版面检测、表格识别和图表解析等多个独立模块，VLM 可以在单次页面理解过程中同时生成文本块、表格、图像说明、实体和关系等结构化结果，从而降低多模块级联带来的误差累积和工程复杂度。

近年来的通用 VLM 也开始针对文档、图表和长上下文任务进行强化。例如 Qwen3-VL 系列支持图像、文本等多模态输入，并在 OCR、空间感知、长上下文理解和多模态推理方面进行了优化^[3]，适合用于 PDF 页面解析和问答生成。但如果直接将整篇多页 PDF 交给 VLM 进行问答，一方面会带来较高的输入 token 成本，另一方面也容易受到长文档上下文稀释、页间定位困难和证据不可追踪等问题影响。因此，本项目并不将 VLM 作为唯一的端到端问答模块，而是将其分别用于知识库构建阶段的页面结构化解析，以及问答阶段的证据综合与答案生成。

综合来看，纯文本 RAG 结构简单但难以利用图像、表格和版式信息；文本

GraphRAG 能基于实体和关系进行多跳扩展，但仍需要外部模块补充视觉证据；VLM 具备强视觉理解能力，却不适合无筛选地承担整篇长 PDF 的全部检索和推理工作。基于上述分析，本项目采用“FAISS + 异构文档图 + 页面图像 + VLM”的技术路线：先通过向量检索和图结构扩展定位候选证据，再将少量相关页面图像及其结构化节点交给 VLM 生成答案，从而在可追溯性、多模态理解能力和 token 成本之间取得平衡。

3 系统设计与实现

3.1 总体架构

本系统面向多页 PDF 文档中的多模态问答任务，整体上由知识库构建和在线问答两条链路组成。知识库构建链路负责将原始文档转化为可检索、可关联、可追溯的多模态知识表示；在线问答链路则根据用户问题从知识库中定位相关证据，并结合视觉语言模型生成最终回答。系统总体架构如图 3.1 所示。




图 3.1 系统总体架构

在知识库构建阶段，系统首先使用 PyMuPDF 将 PDF 按页转换为图像，以保留页面中的版式、图表、表格和视觉上下文。随后，系统调用 Qwen3-VL-8B-Instruct 对每一页进行结构化理解，抽取正文段落、表格内容、图表说明、页面结论、关键词以及语义关系。经过规范化处理后，这些内容同时进入基于 FAISS 的向量索引和基于 NetworkX 的异构文档图中。向量索引用于支持语义相似度检索，文档图用于表达页面内部和页面之间的结构关系，页面图像则作为后续回答阶段的重要视觉证据。三类信息共同构成系统的多模态知识库。

在线问答阶段，系统并不直接把整篇 PDF 交给模型处理，而是先根据用户问题进行证据筛选。系统先利用 DashScope text-embedding-v3 生成问题向量，并在 FAISS 索引中获得语义相关的候选内容，再借助文档图扩展同页内容、关键词关联、跨页延续和图文对应关系，最后选取少量相关页面图像与文本证据共同输入

Qwen3-VL-8B-Instruct。这样既能减少长文档输入带来的 token 开销，也能提高证据定位的可解释性。

3.2 文档解析与结构化抽取

多页 PDF 文档往往同时包含正文、表格、图表、脚注、标题层级和跨页延续内容。若只依赖纯文本抽取，表格结构、图表含义和版面关系很容易丢失。因此，本系统在文档解析阶段保留页面图像，并利用 Qwen3-VL-8B-Instruct 直接理解页面整体内容。该模型不仅识别页面中的文字，还会根据版面位置和视觉线索判断不同内容块之间的关系。

解析结果会被统一整理为若干类文档元素，包括文本片段、表格、图表、页面级结论以及关键词信息。对于表格，系统保留其行列结构和主要数值；对于图表，系统保留图表编号、主题描述和视觉含义；对于正文内容，系统保留其页码来源和上下文位置。这样处理后，文档不再只是连续的纯文本，而是由多个带有来源信息的多模态证据单元组成。

为了提高解析稳定性，系统在抽取结果过于稀疏或格式不完整时会进行补充解析，并对异常结果进行容错处理。其目的不是追求复杂的工程细节，而是保证每一页至少能够形成可检索的基本内容表示。最终，所有文档元素都会带有稳定的来源信息，使系统能够在回答时追溯到具体文档和页面。

3.3 知识图谱构建

系统采用向量索引和异构文档图共同组织知识。向量索引由 text-embedding-v3 和 FAISS 构成，适合处理语义相似的召回问题，例如用户问题和某段正文表述并不完全一致时，仍然可以通过语义匹配找到相关内容。异构文档图由 NetworkX 进行组织，用于表达文档内部更明确的结构关系，例如同一页中的图文邻近关系、关键词与内容之间的锚定关系、相邻页面之间的文本延续关系，以及由模型抽取出的语义关联。

在图结构中，节点可以表示正文片段、表格、图表、页面结论或关键词等不同类型的信息。边则表示这些信息之间的联系，例如同页共现、主题相关、上下文延续和跨页合并。相比单纯的向量检索，这种图结构能够帮助系统从一个证据点扩展到相关证据点，尤其适合回答需要多跳推理、跨页整合或结合图表与正文的问题。

文档图并不是为了替代向量检索，而是作为语义召回之后的结构化补充。向量检索负责快速找到与问题最接近的候选内容，图结构负责沿着文档关系扩展上

下文。系统还采用 **greedy modularity communities** 算法对文档图进行社区划分，使问答阶段能够获得主题层面的全局补充证据。二者结合后，系统既能保持检索效率，又能减少只依赖片段相似度带来的上下文缺失问题。

3.4 GraphRAG 问答流程

在线问答流程可以概括为证据召回、图谱扩展、证据融合和答案生成四个阶段。首先，系统根据用户问题在向量索引中检索语义相关内容，得到初始证据。随后，系统在文档图中围绕这些证据进行关系扩展，补充同页内容、关键词关联内容和跨页连续内容。对于涉及全局主题的问题，系统还会利用图中的社区结构补充更高层次的上下文。

证据融合阶段会对候选内容进行筛选和组织。系统会优先保留与问题相关度高、来源明确、能够相互补充的文本证据和页面图像。对于包含表格或图表的问题，页面图像能够为视觉语言模型提供原始视觉依据；对于跨页问题，图结构能够帮助系统把分散在不同页面的内容连接起来。最终输入模型的不是整篇文档，而是一组经过筛选的证据集合。

答案生成阶段由 **Qwen3-VL-8B-Instruct** 完成。模型会综合文本证据、结构关系和相关页面图像，生成自然语言回答，并返回与回答相关的页面和证据来源。由于回答建立在检索到的证据集合之上，用户不仅能够看到最终答案，也能够进一步查看答案依据的页面和图谱节点，从而提升系统的可追溯性。

3.5 前后端交互设计

系统后端基于 **Flask** 实现，负责文档入库、问答调用、图谱读取和证据资源管理。文档入库任务通常耗时较长，因此后端需要处理任务状态、并发控制和结果缓存等问题。问答接口则需要在较短时间内完成检索、图谱扩展、证据组织和模型调用。为了保证系统能够稳定运行，后端还对大规模图谱数据和页面资源进行了缓存与压缩处理。

系统网页界面如图 3.2 所示。前端围绕问答和证据查看两个核心需求设计，将对话区、知识图谱区和节点详情区整合在同一工作空间中。用户可以在左侧对话区域输入问题并查看模型回答，回答内容以 **Markdown** 形式渲染，便于展示分点说明、引用信息和结构化结论。页面中部展示由 **vis-network** 生成的交互式知识图谱，用户可以通过缩放、拖拽和点击节点观察文档中的文本、表格、图表、关键词及其关系。右侧节点详情区用于展示当前选中节点的来源文档、页码、内容摘要和页面预览，使用户能够从模型答案进一步追溯到原始证据。




图 3.2 系统网页交互界面

从功能上看，该网页不仅承担普通问答入口的作用，还提供了知识结构浏览和证据核查能力。对话区负责承载用户问题和系统回答，知识图谱区负责呈现文档知识库的整体结构，节点详情区则负责连接抽象图谱节点与具体页面证据。当用户在图谱中选择某个节点时，系统会展示该节点的类型、来源页码、文本内容以及相关页面预览；对于图表和表格节点，页面预览还能帮助用户检查模型回答是否与原文视觉证据一致。这样的设计使系统不仅是一个问答工具，也能够作为文档知识结构的浏览和分析工具。

总体而言，本系统的实现重点不是简单地把 PDF 上传给大模型，而是先将文档转化为可检索、可关联的多模态知识空间，再通过 GraphRAG 流程选择必要证据并完成回答。该设计在回答质量、证据可追溯性和 token 成本之间形成了较好的平衡，也为后续消融实验和 token 对比实验提供了清晰的系统基础。

4 实验设计与结果分析

本章系统评估多模态 GraphRAG 系统的问答性能，介绍实验设置、消融实验结果和错误分析。

4.1 实验设置

4.1.1 数据集

我们从 pdfQA/ClimRetrieve 文档集中选取 12 篇 ESG 可持续发展报告（涵盖 Microsoft、AT&T、AstraZeneca、Boeing、Coca-Cola、Meta、Walmart 等多个行业），构建了包含 **120 道问答对** 的自建测试集，覆盖六种问题类型：文本定位（30 题，25%）、表格问答（27 题，22.5%）、图表理解（17 题，14.2%）、跨页延续（22 题，18.3%）、多跳关系（12 题，10%）和引用追踪（12 题，10%）。每道问题标注了标准答案、问题类型、难度等级和证据页码。

4.1.2 评测指标

- (1) **ANLS**: DocVQA 官方指标，归一化编辑距离（阈值 0.5）。
 - (2) **Token F1**: 基于字符 bigram 的 F1 分数，对中文友好。
 - (3) **Heuristic Judge**: 规则组合评分, $EM=1.0$ 、 $Containment=0.9$ 、 $Token F1 \geq 0.8=0.8$ 、 $Token F1 \geq 0.5=0.5$ 、 $Token F1 \geq 0.3=0.25$ 、其余 0。
 - (4) **Evidence Page Recall**: 预测页码与标准证据页码有交集的样本比例。
- 所有指标均经 NFKC 规范化处理，多标准答案取下最大值。

4.1.3 消融方案

五组消融实验设计如下：

- (1) **none**: 该组不使用 FAISS 向量检索、异构文档图和页面图像证据，用于观察模型在缺少外部文档证据时的基线表现。
- (2) **vector_only**: 该组仅使用 FAISS 向量检索定位相关文本证据，用于检验纯语义召回在多页文档问答中的作用。
- (3) **graph_only**: 该组仅使用异构文档图进行证据扩展，用于检验结构关系和跨页关联对回答生成的贡献。
- (4) **no_image**: 该组同时使用 FAISS 向量检索和异构文档图，但不输入页面图像证据，用于分析视觉信息对表格、图表和版式相关问题的影响。
- (5) **full**: 该组完整使用 FAISS 向量检索、异构文档图和页面图像证据，用于代

表系统的完整多模态 GraphRAG 流程。

所有实验使用相同的 120 道问题和 Qwen3-VL-8B-Instruct 模型，仅改变证据召回和输入配置，以保证不同组别之间具有可比性。

4.2 实验结果

4.2.1 整体性能

五组消融实验的整体结果如图 4.1 和表 4.1 所示。完整系统在所有四项指标上均取得最优成绩。




图 4.1 五组消融实验四项核心指标对比

表 4.1 五组消融实验整体指标数值

指标	none	graph_only	vector_only	no_image	full
ANLS	0.0088	0.0044	0.0549	0.0790	0.0840
Token F1	0.1924	0.4007	0.5704	0.6074	0.6185
Heuristic Judge	0.1042	0.3042	0.4408	0.4750	0.4813
Evidence Page Recall	0.0000	0.8917	0.8750	0.9167	0.9250

4.2.2 消融分析

图 4.2 展示了各组件的增量贡献（以 ANLS 为指标），核心发现如下：




图 4.2 组件增量贡献（ANLS 瀑布图）

(1) **FAISS 向量检索是最关键的组件。** `vector_only` 的 ANLS (0.0549) 是 `graph_only` (0.0044) 的 12.5 倍，Token F1 和 Heuristic Judge 也显著领先。仅有图谱关键词匹配无法提供足够的语义覆盖，FAISS 的稠密语义召回是不可替代的基础。

(2) **图谱扩展提供额外增益。** 对比 full 与 `vector_only`，引入图谱后 ANLS 提升 53.1% (0.0549 → 0.0840)，Token F1 提升 8.4%，Evidence Page Recall 提升 5.7%。图谱邻域扩展增强了语义证据广度，提升了页面定位准确性。

(3) **页面图像有正向贡献但幅度较小。** 移除图像后 ANLS 下降 6.0%，Token F1 下降 1.8%，说明当前文档的文本抽取质量较高，图像主要对图表理解和视觉细节问题发挥作用。

(4) **`graph_only` 的“高召回、低准确”现象值得关注。** `graph_only` 的 Evidence Page Recall (0.8917) 与 `vector_only` (0.8750) 相当，但 ANLS 仅为 0.0044。图谱可通过关键词找到正确页面，但从页面提取的文本证据质量不足，导致模型“看对了地方”却“答不对问题”。

4.2.3 按问题类型分析

图 4.3 和表 4.2 展示了完整系统在六种问题类型上的性能分布。`text_location` 和 `table_qa` 表现最好 (ANLS 0.15 和 0.12，Heuristic Judge 约 0.50)，FAISS 检索能准确定位单页内的文本和表格信息。`cross_page` 和 `chart_understanding` 居中，跨页证据合并和图表视觉推理仍有改进空间。`multi_hop` 和 `citation_tracking` 的 ANLS 为零，但 Token F1 约 0.59，说明回答语义上存在重叠——零 ANLS 主要因长答案多

等价表述导致编辑距离评分失效。




图 4.3 完整系统按问题类型的 ANLS 与 Token F1 对比

表 4.2 完整系统按问题类型的指标分布

问题类型	数量	ANLS	Token F1	Heuristic Judge
text_location	30	0.1535	0.6305	0.4767
table_qa	27	0.1218	0.6461	0.5019
chart_understanding	17	0.0989	0.6102	0.4765
cross_page	22	0.0232	0.6018	0.4795
multi_hop	12	0.0000	0.5898	0.4792
citation_tracking	12	0.0000	0.5976	0.4583

4.3 Token 成本分析

DocRAG 每次问答仅向 VLM 发送检索筛选后的相关页面和文本证据，而非整个文档。为了量化这一设计对调用成本的影响，本文将 DocRAG 问答流程与直接上传目标 PDF 的全量问答方式进行对比。两种方式使用相同的问题集合，统计模型调用中的输入 token、输出 token 和总 token。实验共选取 20 道真实 PDF 问题，其中 13 道问题在两种方式下均成功返回结果，因此表 4.3 以这 13 个有效配对样本作为统计口径。

从表 4.3 可以看出，全量上传方式在每次问答中都需要重新处理完整 PDF，因此平均输入 token 达到 42,145；DocRAG 则通过检索和图谱扩展先定位少量相关证据，平均输入 token 降至 2,236，仅为全量上传方式的约 5.31%。换言之，DocRAG 在输入侧节省了 94.69% 的 token。输出 token 由于本实验要求模型给出简短答案，

表 4.3 DocRAG 与全量上传方式的 Token 成本对比

统计项	DocRAG	全量上传 PDF	相对全量上传变化
有效配对样本数	13	13	—
输入 Token 总数	29,071	547,890	减少 94.69%
总 Token 数	29,097	547,903	减少 94.69%
平均输入 Token	2,236	42,145	减少 94.69%
平均总 Token	2,238	42,146	减少 94.69%

两种方式的数值都很小，且 DocRAG 略高于全量上传方式，因此不构成主要成本差异。总体来看，token 成本优势主要来自输入侧压缩，说明先检索再生成的流程能够在保持证据可追溯的同时显著降低长 PDF 问答的调用开销。

图 4.4 进一步直观展示了输入 token 节省比例。这一优势在多轮对话和批量评测场景下尤为显著，因为全量上传方式会在每轮问答中重复传入整篇文档，而 DocRAG 只需传入与当前问题相关的局部证据。




图 4.4 DocRAG vs 全量上传：估算输入 Token 节省率

4.4 错误分析

通过人工审查低分样本，归纳四类主要错误模式：

- (1) **检索跨度不足**：FAISS 召回可能仅命中跨页起止页中的一页，continuation 边未将另一端文本引入证据集。
- (2) **答案格式冗长**：VLM 即使 short 模式也输出大量铺垫，导致与简洁标准答案的 ANLS/EM 偏低。
- (3) **图表视觉推理脱节**：模型有时仅依赖文本形式的图表描述，忽略页面原图中

的视觉细节（趋势线斜率、柱状图相对高度）。

- (4) **多跳证据链断裂**：multi_hop 问题需在不同节点间建立推理链，当中间节点的语义关系边存在噪声或缺失时，证据链中断。

4.5 人工评分交叉验证

自动指标（尤其是 ANLS 和 Exact Match）对长答案的语义等价不敏感：当模型给出内容正确但表述不同的回答时，编辑距离类指标往往给出低分。为交叉验证自动指标的可靠性，本节从测试集中选取了 4 篇文档（Meta 2023 Sustainability Report、Veolia ESG Report 2023、Walmart ESG Highlights 2023、Westpac 2023 Climate Report），对其共计 40 道问题进行人工三档评分，并与 Heuristic Judge 进行对比分析。

4.5.1 评分标准

人工评分采用三档制，以标准答案的任意变体为基准，不要求逐字匹配：

- (1) **正确 (1.0)**：核心事实与标准答案一致，关键数据/结论正确，无重大遗漏。
- (2) **部分正确 (0.5)**：触及核心但存在关键数据偏差、遗漏重要子问题、部分信息不准确或回答过于泛化。
- (3) **错误 (0.0)**：关键事实错误、答非所问、或模型表示“证据不足”但标准答案有明确信息。

多子问题等权重独立判断；模型给出额外合理信息不扣分。加权准确率定义为：

$$\text{加权准确率} = (N_{\text{正确}} \times 1.0 + N_{\text{部分正确}} \times 0.5) / 40$$

4.5.2 整体结果

40 道问题的人工评分整体分布如表 4.4 所示。

表 4.4 人工评分整体分布 (40 题)

评分等级	数量	占比
正确 (1.0)	19	47.5%
部分正确 (0.5)	15	37.5%
错误 (0.0)	6	15.0%
加权准确率	0.6625	

加权准确率为 66.3%，显著高于 Heuristic Judge 对同 40 题的平均分 (0.496)。

这说明模型回答的实质语义质量优于编辑距离类指标所反映的水平，大量“部分正确”回答被自动指标系统性低估。

4.5.3 按文档分析

四篇文档的人工加权准确率如表 4.5 所示。

表 4.5 人工评分与 Heuristic Judge 按文档对比

文档	人工加权准确率	Heuristic Judge	差距
Veolia ESG Report 2023	0.750	0.500	+0.250
Meta 2023 Sustainability Report	0.700	0.530	+0.170
Walmart ESG Highlights 2023	0.600	0.425	+0.175
Westpac 2023 Climate Report	0.600	0.530	+0.070
平均	0.663	0.496	+0.167

Veolia 表现最好 (0.750)，Walmart 和 Westpac 相对较弱 (0.600)。值得注意的是，Westpac 的 Heuristic Judge 评分 (0.530) 与 Veolia (0.500) 相当甚至略高，但人工评分差距达 0.150，再次说明自动指标可能高估部分文档的表现。

4.5.4 按题型分析

各题型的表现差异明显（表 4.6）。

表 4.6 人工评分按题型分布

题型	数量	加权准确率	Heuristic Judge	差距
text_location	12	0.792	0.500	+0.292
table_qa	9	0.722	0.506	+0.217
chart_understanding	4	0.625	0.500	+0.125
cross_page	7	0.643	0.471	+0.172
citation_tracking	4	0.375	0.500	-0.125
multi_hop	4	0.125	0.500	-0.375

text_location 和 table_qa 表现最好（加权准确率 > 0.7），这两类问题对单页文本和表格信息的定位需求明确，FAISS 检索能有效覆盖。multi_hop 表现最弱（4 题中 3 题得 0 分，加权准确率仅 0.125），主要原因是中间节点的语义关系边存在噪声或缺失，导致多跳推理链条中断。citation_tracking 次弱（0.375），模型在给定页码时频频出错。

一个令人警惕的现象是：multi_hop 和 citation_tracking 的人工加权准确率远低

于 Heuristic Judge (差距分别为 -0.375 和 -0.125)，这意味着自动指标在这两类题型上存在严重的假阳性问题——模型输出的文本因包含实体名称和数值关键词而获得较高自动分，但实际回答的关键事实是错误的。

4.5.5 自动指标可靠性分析

将人工评分与 Heuristic Judge 逐题配对进行 Spearman 秩相关性分析，系数仅为 0.387 ($p < 0.05$)，属于弱正相关。进一步识别出以下典型不一致案例：

- (1) **假阳性 (5 例)**：Heuristic Judge ≥ 0.5 但人工评分为 0.0 。这 5 例全部集中在 multi_hop 和 citation_tracking 题型，共同特征是模型输出包含与标准答案相同的实体名称和数值，但关键关系或归因完全错误，自动指标仅凭表面词级匹配无法识别。
- (2) **假阴性 (1 例)**：Heuristic Judge = 0.25 但人工评分为 1.0 (Walmart 员工构成数据题)。模型回答数据完全正确，但因表述顺序与标准答案不同导致 Token F1 下降，进而拉低 Heuristic Judge。

综合以上分析，本节的人工评分交叉验证得出三点主要结论：第一，完整系统在人工三档评分下的加权准确率达到 66.3% ，高于自动指标所反映的水平，系统具有实际可用性；第二，自动指标（尤其是 Heuristic Judge 和 ANLS）对 multi_hop 和 citation_tracking 类长答案存在系统性高估或低估，不应单独作为评测依据；第三，在资源允许的情况下，建议将人工抽检作为自动评测的必要补充。

4.6 实验小结

本章通过五组消融实验验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性：完整系统在全部指标上最优，FAISS 语义召回是最关键的单一组件，图谱和图像提供额外增益，页面级证据定位达 92.5% 召回率。Token 分析表明 DocRAG 相比全量上传可节省约 94% 的输入 token。

5 总结与展望

5.1 主要工作总结

本文设计并实现了一个完整的多模态 GraphRAG 文档问答系统，主要工作包括：

- (1) **构建了面向多页 PDF 的多模态解析流程**：本文以 PDF 文档为核心输入，利用视觉语言模型对 PDF 中的正文、表格、图表和页面结论进行统一理解，使系统能够在保留版式与视觉上下文的基础上形成可检索的结构化证据。相比单纯依赖文本抽取的方法，该流程更适合处理图表密集、页面结构复杂的真实文档。
- (2) **设计了融合语义与结构关系的文档知识表示**：本文将文档内容组织为异构文档图，并将向量索引与图结构结合起来。向量索引用于发现语义相关内容，文档图用于刻画同页关联、关键词锚定、跨页延续和图文对应等关系，从而为跨页问答和多跳推理提供更完整的上下文支持。
- (3) **实现了多阶段 GraphRAG 问答机制**：本文提出先语义召回、再图谱扩展、最后多模态融合的问答流程，使系统能够从长文档中筛选出少量关键证据，并结合相关页面图像生成答案。该机制避免了直接输入整篇 PDF 带来的上下文稀释和 token 成本过高问题，同时保留了答案来源的可追溯性。
- (4) **完成了可交互的文档问答系统原型**：本文实现了从文档入库、知识库构建、问题回答到证据查看的完整系统链路。用户不仅可以获得自然语言回答，还可以通过知识图谱和页面预览查看答案依据，从而提升系统在复杂文档分析场景中的可用性和解释性。
- (5) **开展了系统性的实验验证**：本文基于 pdfQA 相关文档构建了包含 120 道问题的测试集，覆盖文本定位、表格问答、图表理解、跨页延续、多跳关系和引用追踪等类型。消融实验表明，完整系统在主要指标上取得最优结果，其中 Token F1 达到 0.619，Heuristic Judge 达到 0.481，证据页召回率达到 0.925，说明向量检索、图谱扩展和多模态证据融合均对系统性能具有实际贡献。除自动指标外，本文还引入人工评分交叉验证，从答案正确性、完整性和证据支撑等角度对系统输出进行补充分析，使实验结论不仅依赖字符串匹配结果，也能反映长答案问答中的语义质量。

5.2 局限性与未来展望

当前系统存在以下局限：VLM 抽取的语义关系边存在噪声，多跳推理链条不够稳定；跨页延续边权重为二值化，缺乏语义连续性强度的精细度量；答案格式控制不足导致 ANLS 偏低；图谱在入库后为静态结构，未根据查询动态调整。未来可从以下方向改进：

- (1) **提升图谱检索的动态性**：当前系统的图谱结构主要在入库阶段形成，问答阶段对不同问题的适应能力仍然有限。后续可以借鉴查询驱动的 GraphRAG 思路^[6]，根据问题意图动态选择和加权图谱中的相关区域，使检索过程更贴合具体任务需求。
- (2) **完善长答案的语义级评测**：现有评测指标对短答案和定位类问题较为直观，但对综合型长答案的语义一致性刻画仍不充分。后续可以引入语义相似度评测和大模型辅助评判，以更准确地衡量回答是否覆盖关键事实、是否存在遗漏以及是否与证据一致。
- (3) **增强模型在文档任务上的适配能力**：通用视觉语言模型虽然具备较强的页面理解能力，但在复杂表格、细粒度图表推理和规范化引用输出方面仍存在不稳定现象。未来可以结合文档问答样本进行轻量化微调，使模型更适应本系统面对的多页 PDF 场景。
- (4) **加强答案可信度与证据归因**：当前系统能够返回相关页面和图谱节点，但答案中的每个关键断言与具体证据之间尚未形成足够细粒度的对应关系。后续可以进一步建立断言级证据匹配机制，使用户能够判断答案中的每一部分来自哪些页面和内容块，从而降低幻觉风险。
- (5) **扩展到多文档联合分析**：本文主要关注单篇 PDF 内部的多模态问答，而真实应用中经常需要比较多份报告或综合多个来源的信息。未来可以在现有文档图的基础上建立跨文档关联，使系统支持跨报告对比、趋势分析和多来源综合问答。

综上所述，本文验证了“向量检索 + 异构图谱 + VLM”技术路线在多图 PDF 文档问答场景中的可行性。实验结果表明，向量检索能够提供高效的语义召回，异构图谱能够补充跨页和结构化上下文，页面图像能够增强表格、图表和版式相关问题的理解能力。同时，token 对比实验表明，相比直接上传完整 PDF 的问答方式，本文方法通过先检索再生成的流程显著降低了模型输入成本，在真实 PDF 评测样本上可节省约 94% 的输入 token。总体来看，本系统在回答质量、证据可追溯性和调用成本之间取得了较好的平衡，为面向复杂多模态文档的可解释问答系统提供了可复用的设计思路。

参 考 文 献

- [1] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]. Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 9459-9474.
- [2] Edge D, Trinh H, Cheng N, et al. From local to global: A graph RAG approach to query-focused summarization[A]. 2024.
- [3] Qwen Team. Qwen3-VL official repository and Qwen3-VL-8B-Instruct model card[Z]. 2025.
- [4] Johnson J, Douze M, Jégou H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547.
- [5] Microsoft. Microsoft GraphRAG documentation: Query engine overview and indexing overview [Z]. 2025.
- [6] Bu C, Jiang Y, Xu J, et al. Query-driven multimodal GraphRAG: Dynamic local knowledge graph construction for online reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2025.
- [7] Mathew M, Karatzas D, Jawahar C V. DocVQA: A dataset for VQA on document images[C]. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2021: 2200-2209.
- [8] Masry A, Long D X, Tan J Q, et al. ChartQA: A benchmark for question answering about charts with visual and logical reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2022.
- [9] Faysse M, Colombo P, Piccardi T, et al. ColPali: Efficient document retrieval with vision language models[A]. 2024.
- [10] Dong K, Zhao Y, Xu W, et al. Benchmarking retrieval-augmented multimodal generation for document question answering[A]. 2025.
- [11] Liu H, Li C, Wu Q, et al. Visual instruction tuning[C]. Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [12] Zhu D, Chen J, Shen X, et al. MiniGPT-4: Enhancing vision-language understanding with advanced large language models[C]. International Conference on Learning Representations (ICLR). 2024.

致 谢

感谢刘阳老师在课程“多模态大模型原理与应用”中的悉心指导，以及在选题讨论和实验方案优化中提供的宝贵建议。感谢小组成员之间的通力合作，三位成员在项目过程中分工明确、协作紧密，充分运用了 **Agentic Engineering** 的方法论，并通过 **Git Worktree** 实现并行协作，最终完成了这一跨模块整合的系统。

还要感谢所有开源社区和研究者，他们开放的模型（**Qwen3-VL**）、数据集（**pdfQA**）、框架（**LangChain**、**FAISS**、**NetworkX**）和研究成果为本项目提供了不可或缺的基础。本项目所有代码已开源于 **GitHub**(<https://github.com/Lem0npiece/Document-RAG>)，供后续课程同学参考和改进。

2026 年 6 月