



本科生毕业论文（设计）

题目：文档理解与多模态 GraphRAG 检索问答系统结题报告

姓名 丁子睿、梁力航、李俊璋

学号 23336058、23336128、23336113

院系 计算机学院

专业 计算机科学与技术

指导教师 刘阳

2026 年 6 月 3 日

摘 要

传统文本检索增强生成 (RAG) 在处理图文混排、跨页引用和结构复杂的长文档时, 存在视觉信息丢失、结构关系不足和证据链不可解释等问题。本文设计并实现了一个多模态 GraphRAG 文档问答系统, 围绕“FAISS 向量索引 + networkx 异构文档图 + 页面图像 + 视觉语言模型”的技术路线, 实现了从文档入库、结构化解析、向量索引与知识图谱构建到多模态检索与答案生成的完整链路。系统使用 PyMuPDF 渲染 PDF 页面图像, 调用 qwen3-vl-8b-instruct 进行结构化抽取, 将文本、表格、图表、结论、关键词和关系同时写入 FAISS 索引和异构文档图谱; 在问答阶段融合向量语义召回、图谱邻域扩展和社区级全局补充, 最终由 VLM 基于多模态证据生成可追溯引用的答案。

实验方面, 基于 12 篇 ESG 报告构建了 120 道覆盖六种类型 (文本定位、表格问答、图表理解、跨页延续、多跳关系、引用追踪) 的自建测试集, 通过五组消融实验系统评估各组件贡献。结果表明, 完整系统在全部指标上均最优 (ANLS 0.084、Token F1 0.619、Heuristic Judge 0.481、证据页面召回率 0.925), 验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性。消融分析揭示 FAISS 语义召回是最关键的单一组件, 而知识图谱和页面图像对证据定位和视觉推理起到了重要补充作用。

关键词: 文档理解, 检索增强生成, GraphRAG, 多模态问答, 视觉语言模型, 知识图谱

目 录

1 绪论	1
1.1 研究背景与意义	1
1.2 研究目标与内容	2
1.3 论文组织结构	2
2 相关工作	4
2.1 检索增强生成 (RAG)	4
2.2 图增强检索与 GraphRAG	4
2.3 多模态文档理解与问答	4
2.4 视觉语言模型	5
3 系统设计与实现	6
3.1 总体架构	6
3.2 文档解析与结构化抽取	7
3.3 知识图谱构建	7
3.4 向量索引与 GraphRAG 检索	7
3.5 后端与前端	8
4 实验设计与结果分析	9
4.1 实验设置	9
4.2 实验结果	9
4.3 Token 成本分析	12
4.4 错误分析	12
4.5 实验小结	13
5 总结与展望	14
5.1 主要工作总结	14
5.2 局限性与未来展望	14
参考文献	16
致谢	17

1 绪论

1.1 研究背景与意义

随着大语言模型 (Large Language Models, LLMs) 的飞速发展, 其在自然语言理解与生成任务上展现出卓越的能力。然而, 纯参数化的 LLM 面临知识时效性不足、事实性偏差 (幻觉) 以及难以追溯推理依据等问题。检索增强生成 (Retrieval-Augmented Generation, RAG) 技术通过在生成回答前从外部知识库检索相关证据, 将参数化知识与非参数化外部知识相结合, 有效缓解了上述问题^[1]。RAG 的核心价值在于提升知识密集型任务的事实性、可更新性和证据可追踪性, 已在企业知识问答、学术文献分析、法律文书检索等场景得到广泛应用。

然而, 真实世界中的文档远非纯文本集合。学术论文、企业财报、技术手册、合同文书和教学课件等文档通常同时包含正文、公式、表格、图表、图像、图注、脚注、跨页段落和图表引用等多种信息形态。传统文本 RAG 主要依赖 OCR 或 PDF 文本抽取后的纯文本向量相似度匹配, 在处理这类图文混排的复杂文档时面临三个根本性挑战:

1. **视觉信息丢失**: 图表趋势、版面结构、颜色标记、坐标轴和表格边界等视觉信息很难被纯文本准确保留。许多关键语义 (如折线图的趋势方向、柱状图的对比关系、流程图的步骤先后) 天然依赖视觉表达, 仅靠文本描述难以完整捕捉。
2. **结构关系不足**: 同一页内的图文对应关系、跨页段落的延续关系、图号与结论之间的支撑关系、关键词与内容片段的锚定关系等, 很难仅通过向量相似度稳定表达。真实文档中的重要信息往往不是线性排列, 而是通过复杂的引用关系相互关联。
3. **证据链不可解释**: 向量检索擅长找到与查询语义相似的孤立文本片段, 但不擅长回答“某结论由哪些图表和实验支撑”这类多跳推理问题。用户难以追溯答案的证据来源和推理路径。

GraphRAG 技术通过在传统 RAG 的基础上引入图结构, 为解决上述问题提供了新的思路。GraphRAG 将知识库中的文本片段、实体、概念、关系和事件组织为知识图谱, 使检索不仅依赖语义相似度, 还能沿图谱中的关系边进行多跳扩展^[2]。对于文档问答而言, 图结构可以将页面、图表、表格、段落、关键词和结论等异质元素统一组织到同一证据空间中, 通过显式的关系边捕获跨页延续、图文支撑和多跳推理路径。

与此同时, 视觉语言模型 (Vision-Language Models, VLMs) 的快速发展为多模

态文档理解提供了强大的技术基础。以 Qwen-VL 系列为代表的视觉语言模型能够直接接收页面图像和文本提示，完成 OCR 识别、版面理解、图表描述、结构化抽取和视觉问答等任务^[3]。这为构建端到端的多模态文档问答系统提供了便利：不再需要组合 OCR 引擎、版面分析器、表格识别器等多个独立模块，而是由一个统一的 VLM 完成多模态文档理解的各项子任务。

1.2 研究目标与内容

本项目面向中山大学 2025–2026 春季学期“多模态大模型原理与应用”课程题目 3“文档理解 + 多模态检索问答系统”，目标是设计并实现一个能够处理 PDF、扫描文档、论文页面和演示文稿截图的多模态 GraphRAG 文档问答系统。

本研究的核心问题是：

对于图文混排、跨页引用和结构复杂的长文档，如何把页面视觉信息、文本语义片段和知识图谱关系融合到同一条检索问答链路中，使回答既能利用多模态证据，又能给出可追溯的页码、节点和关系依据？

围绕这一核心问题，本项目的具体研究内容包括：

1. **多模态文档解析与结构化**：设计基于 VLM 的页面图像结构化抽取流水线，从文档页面中同时提取文本块、表格、图表描述、结论、关键词和语义关系，生成结构化的多模态文档表示。
2. **异构图谱构建**：设计面向文档问答的异构文档图结构，将文本、表格、图表、结论、关键词等内容节点通过同页边、关键词边、跨页延续边和语义关系边组织为统一的知识图谱。
3. **GraphRAG 检索与生成**：设计融合向量检索、图谱邻域扩展和社区级全局补充的多阶段检索策略，以及将文本证据、关系路径和页面图像融合为多模态上下文的答案生成方法。
4. **系统实现与前端可视化**：实现完整的端到端系统原型，包括文档入库、知识库管理、在线问答、图谱可视化等核心功能，提供可交互的 Web 界面。
5. **实验评测与消融分析**：构建自建测试集，设计多组消融实验，系统性评估向量检索、知识图谱和多模态证据各组件对问答性能的贡献。

1.3 论文组织结构

本文其余章节的组织如下：

- **第二章相关工作**：系统回顾 RAG、GraphRAG、多模态文档理解和视觉语言模型等领域的研究现状，分析现有工作的优势与不足，明确本项目的技术定

位。

- **第三章系统设计与实现：**详细阐述系统的总体架构、核心模块设计、关键技术实现细节，包括文档解析流水线、图谱构建算法、GraphRAG 检索与生成策略、后端 API 和前端界面。
- **第四章实验设计与结果分析：**介绍自建测试集的构建过程、评测指标设计、消融实验方案，报告并分析五组消融实验的定量结果，讨论不同组件对系统性能的影响。
- **第五章总结与展望：**总结本文的主要工作和贡献，分析系统的局限性，展望未来改进方向。

2 相关工作

本章从检索增强生成、图增强检索、多模态文档理解和视觉语言模型四个方面梳理相关研究。

2.1 检索增强生成 (RAG)

Lewis 等人在 NeurIPS 2020 提出的 RAG 框架证明了“参数知识 + 非参数知识”的组合方式能显著提升知识密集型 NLP 任务的准确性和可追溯性^[1]。典型 RAG 流程将文档切分为文本块并存入 FAISS 等向量数据库^[4]，查询时通过语义相似度检索相关片段交由生成模型作答。然而标准 RAG 将文档处理为独立文本片段，难以处理跨段落、跨页面、多实体关联和证据链推理的复杂问题；在图文混排场景中，PDF 文本抽取或 OCR 阶段还易丢失版面信息、图像语义和表格结构。模块化 RAG 和自反思 RAG 等改进方案主要在文本检索框架内优化，未从根本上解决文档结构关系和多模态信息融合问题。

2.2 图增强检索与 GraphRAG

GraphRAG 引入图结构来组织知识，使检索能沿图关系扩展证据。Edge 等人提出的 GraphRAG 框架将文档构造成实体知识图谱并生成社区摘要，同时支持围绕实体的局部搜索 (Local Search) 和基于社区总结的全局搜索 (Global Search)^[2]。微软官方实现进一步提供了基于 Leiden 算法的层级社区检测和 map-reduce 式全局回答流程^[5]。Bu 等人在 ACL 2025 提出了 Query-Driven Multimodal GraphRAG，强调根据查询语义动态构建局部图以提升跨模态推理^[6]。

现有 GraphRAG 工作主要面向大规模文本语料，构建流程计算成本较高，且对文档页面中的图表、表格和视觉布局等多模态信息利用不足。本项目的路线有所不同：直接从页面图像出发，使用 VLM 进行文本/表格/图表/关键词/关系的一体化抽取，构建轻量异构文档图，在查询时综合使用向量检索、图谱邻域扩展和社区补充，是一种更适合课程项目场景的多模态 GraphRAG 实现。

2.3 多模态文档理解与问答

DocVQA 数据集包含 12,000 余张文档图像和 50,000 余个问题，要求模型从文档图像中阅读文字、理解版面结构并给出抽取式答案^[7]。ChartQA 聚焦图表问答，

涉及柱状图、折线图、趋势比较和简单算术推理^[8]。这些基准揭示了文档问答的关键特征：视觉布局、表格边界、图表形态和图文对应关系本身就是语义的一部分。

在多模态文档检索方面，ColPali 从页面图像直接生成多向量表示并使用 late interaction 检索，表明页面图像本身可作为检索对象^[9]。MMDocRAG 基准进一步强调长文档 RAG 需要选择并整合文本、表格、图像等多模态证据^[10]。这些工作启示我们：文档问答系统应保留页面原图、图表描述、bbox 等信息，同时关注证据引用的准确性和完整性。

2.4 视觉语言模型

LLaVA、MiniGPT-4 等工作通过视觉指令微调使 VLM 能遵循自然语言指令完成视觉推理^[11-12]。Qwen3-VL 系列支持图像、视频和文本的统一理解，在 OCR、空间感知、长上下文和多模态推理方面进行了专门强化^[3]，能在单次推理中同时完成页面文本识别、表格提取、图表理解和结构化 JSON 输出。VLM 的端到端特性使传统文档理解中 OCR、版面分析、表格识别等多模块组合的工程复杂度大幅降低。

综合来看，纯文本 RAG 结构简单但无法处理视觉信息和文档结构关系；文本 GraphRAG 能利用实体和关系做多跳扩展但缺少视觉证据的利用。本项目采用“FAISS + 异构文档图 + 页面图像 + VLM”的技术路线，将 RAG 的可更新性、GraphRAG 的关系扩展能力和 VLM 的视觉理解能力统一到同一条可追溯的文档问答链路中。

3 系统设计与实现

3.1 总体架构

系统围绕“知识库构建”和“在线问答”两条链路展开，总体架构如图 3.1 所示。




图 3.1 系统总体架构

知识库构建链路通过 Flask /ingest 接口接收文件后，调用 build_multimodal_graphrag.py 执行入库：PyMuPDF 将 PDF 渲染为页面图像，qwen3-vl-8b-instruct 进行结构化抽取得到文本、表格、图表、结论、关键词和关系，封装为 LangChain Document 对象。同一批内容被分别写入 DashScope text-embedding-v3 生成的 FAISS 向量索引和 networkx 异构文档图。FAISS 索引、图谱和页面原图通过 node_id、page、source、bbox 等元数据对齐，形成统一的多模态证据空间。

在线问答链路从 /chat 接口进入 MultiModalGraphRAG.ask()：FAISS 语义召回种子节点 → 图谱邻域扩展与二跳桥接 → 社区 profile 全局补充 → 融合文本证据、关系路径与页面原图为多模态 prompt → VLM 生成可追溯答案。前端提供 Chat Workspace、vis-network 图谱可视化和 Node Inspector 三个核心交互区域。

3.2 文档解析与结构化抽取

系统使用 PyMuPDF 将 PDF 页面以 2.0 倍缩放渲染为 PNG，调用 qwen3-vl-8b-instruct 进行七字段结构化抽取：texts（正文/标题/图注，含 bbox）、tables（Markdown 表格）、figures（图表编号/描述/bbox）、section_conclusions（页面结论）、entities（命名实体）、keywords（方法/模型/指标等关键词）、relations（三元组语义关系）。

解析模块包含三类鲁棒性策略：抽取稀疏时自动使用高召回 repair prompt 重试；仍缺少文本块时调用 text-only prompt 兜底；JSON 解析使用字符串扫描定位对象边界配合 raw_decode 容错，非法 JSON 时包装为最小化 text-only Document。所有片段被赋予稳定的 node_id（基于文档哈希、页码和类型），保留完整元数据用于检索、引用和可视化。

3.3 知识图谱构建

本系统的图谱是面向文档问答定制设计的**异构文档图**。节点类型包括：内容节点（text、table、figure、conclusion、cross_page_text）和关键词节点（以 method/model/dataset/metric/task 等分类前缀组织）。边类型包括：same_page（同页上下文）、keyword_hit（关键词与内容锚定）、cooccurrence（同页关键词共现）、continuation（相邻页文本延续）、cross_page_merge（跨页合并联系）和 VLM 抽取的语义关系边。

这种设计使图谱不仅能支撑多跳推理，还能捕获版面结构、跨页延续和图表-文本对应关系。系统故意弱化不稳定的实体节点，优先使用关键词和内容锚点作为图骨架。图谱构建后使用 greedy modularity communities 算法进行社区检测，每个社区被表征为包含关键词分布、页面范围和节点统计的轻量 profile，用于问答阶段的全局上下文补充。

3.4 向量索引与 GraphRAG 检索

3.4.1 向量索引

系统通过 LangChain FAISS 集成和 DashScope text-embedding-v3 构建本地向量索引（支持切换本地 HuggingFace 模型）。每个 Document 的 page_content 在嵌入前拼接类型标签和页码信息以增强类型感知。FAISS 索引支持增量更新：通过 SHA-256 文件签名检查文档是否已存在于 build_meta.json 注册表，仅对新文档执行解析和嵌入。

3.4.2 多阶段检索与生成

问答链 MultiModalGraphRAG 的检索过程分三阶段：(1) FAISS top-k (默认 $k=3$) 语义召回种子节点，支持 `source_hint` 限定文档源；(2) 在文档图中从种子节点执行一跳邻域扩展 (`same_page`、`keyword_hit` 等)，再通过关键词 hub 做二跳桥接，总节点上限 18；(3) 将查询词与社区 `profile` 匹配，按命中数、重叠度和规模选择全局补充证据。

检索完成后构造五层多模态 `prompt`：任务指令 → 图谱关系链 → 全局社区证据 → 文本证据块 → 相关页面原图 (`base64 data URI`)。最终由 `qwen3-vl-8b-instruct` 生成答案，返回 `GraphRAGResult` (含答案、页码、节点 ID、关系路径、图像路径)。系统通过 `use_vectorstore`、`use_graph`、`use_images` 三个布尔标志支持五种消融模式 (`full/vector_only/graph_only/no_image/none`)。

3.5 后端与前端

后端基于 Flask 提供 RESTful API: `/ingest` (文件上传入库, 支持 token 鉴权和互斥锁防并发)、`/chat` (问答, 返回答案与引用)、`/graph` (图谱 JSON, gzip 压缩、含节点级元数据)、`/node/<id>` (节点懒加载) 和 `/outputs/<path>` (静态文件访问)。工程优化包括: 图谱 `mtime` 缓存自动失效、大响应 gzip 压缩和文件名安全清洗。

前端为单页应用 (`web/index.html + web/app.js`)，核心功能包括: Chat Workspace (Markdown 答案渲染、多轮对话)、Knowledge Graph (`vis-network` 交互式图谱, 禁用物理引擎处理 6000+ 节点场景) 和 Node Inspector (节点详情、页面预览和 `bbox Canvas` 裁剪展示)。

4 实验设计与结果分析

本章系统评估多模态 GraphRAG 系统的问答性能，介绍实验设置、消融实验结果和错误分析。

4.1 实验设置

4.1.1 数据集

我们从 pdfQA/ClimRetrieve 文档集中选取 12 篇 ESG 可持续发展报告（涵盖 Microsoft、AT&T、AstraZeneca、Boeing、Coca-Cola、Meta、Walmart 等多个行业），构建了包含 **120 道问答对** 的自建测试集，覆盖六种问题类型：文本定位（30 题，25%）、表格问答（27 题，22.5%）、图表理解（17 题，14.2%）、跨页延续（22 题，18.3%）、多跳关系（12 题，10%）和引用追踪（12 题，10%）。每道问题标注了标准答案、问题类型、难度等级和证据页码。

4.1.2 评测指标

1. **ANLS**: DocVQA 官方指标，归一化编辑距离（阈值 0.5）。
 2. **Token F1**: 基于字符 bigram 的 F1 分数，对中文友好。
 3. **Heuristic Judge**: 规则组合评分, EM=1.0、Containment=0.9、Token F1 $\geq$ 0.8=0.8、Token F1 $\geq$ 0.5=0.5、Token F1 $\geq$ 0.3=0.25、其余 0。
 4. **Evidence Page Recall**: 预测页码与标准证据页码有交集的样本比例。
- 所有指标均经 NFKC 规范化处理，多标准答案取下最大值。

4.1.3 消融方案

五组消融实验设计如下：**full**（FAISS + 图谱 + 图像，完整系统）、**vector_only**（仅 FAISS + 图像）、**graph_only**（仅图谱 + 图像）、**no_image**（FAISS + 图谱，无图像）、**none**（无检索基线）。所有实验使用相同的 120 题和 qwen3-vl-8b-instruct 模型，仅检索配置不同。

4.2 实验结果

4.2.1 整体性能

五组消融实验的整体结果如图 4.1 和表 4.1 所示。完整系统在所有四项指标上均取得最优成绩。




图 4.1 五组消融实验四项核心指标对比

表 4.1 五组消融实验整体指标数值

指标	none	graph_only	vector_only	no_image	full
ANLS	0.0088	0.0044	0.0549	0.0790	0.0840
Token F1	0.1924	0.4007	0.5704	0.6074	0.6185
Heuristic Judge	0.1042	0.3042	0.4408	0.4750	0.4813
Evidence Page Recall	0.0000	0.8917	0.8750	0.9167	0.9250

4.2.2 消融分析

图 4.2 以瀑布图形式展示了各组件的增量贡献（以 ANLS 为指标），核心发现如下：




图 4.2 组件增量贡献（ANLS 瀑布图）

(1) **FAISS 向量检索是最关键的组件。** `vector_only` 的 ANLS (0.0549) 是 `graph_only` (0.0044) 的 12.5 倍，Token F1 和 Heuristic Judge 也显著领先。仅有图谱关键词匹配无法提供足够的语义覆盖，FAISS 的稠密语义召回是不可替代的基础。

(2) **图谱扩展提供额外增益。** 对比 full 与 `vector_only`，引入图谱后 ANLS 提升 53.1% (0.0549 → 0.0840)，Token F1 提升 8.4%，Evidence Page Recall 提升 5.7%。图谱邻域扩展增强了语义证据广度，提升了页面定位准确性。

(3) **页面图像有正向贡献但幅度较小。** 移除图像后 ANLS 下降 6.0%，Token F1 下降 1.8%，说明当前文档的文本抽取质量较高，图像主要对图表理解和视觉细节问题发挥作用。

(4) **`graph_only` 的“高召回、低准确”现象值得关注。** `graph_only` 的 Evidence Page Recall (0.8917) 与 `vector_only` (0.8750) 相当，但 ANLS 仅为 0.0044。图谱可通过关键词找到正确页面，但从页面提取的文本证据质量不足，导致模型“看对了地方”却“答不对问题”。

4.2.3 按问题类型分析

图 4.3 和表 4.2 展示了完整系统在六种问题类型上的性能分布。`text_location` 和 `table_qa` 表现最好 (ANLS 0.15 和 0.12，Heuristic Judge 约 0.50)，FAISS 检索能准确定位单页内的文本和表格信息。`cross_page` 和 `chart_understanding` 居中，跨页证据合并和图表视觉推理仍有改进空间。`multi_hop` 和 `citation_tracking` 的 ANLS 为

零，但 Token F1 约 0.59，说明回答语义上存在重叠——零 ANLS 主要因长答案多等价表述导致编辑距离评分失效。




图 4.3 完整系统按问题类型的 ANLS 与 Token F1 对比

表 4.2 完整系统按问题类型的指标分布

问题类型	数量	ANLS	Token F1	Heuristic Judge
text_location	30	0.1535	0.6305	0.4767
table_qa	27	0.1218	0.6461	0.5019
chart_understanding	17	0.0989	0.6102	0.4765
cross_page	22	0.0232	0.6018	0.4795
multi_hop	12	0.0000	0.5898	0.4792
citation_tracking	12	0.0000	0.5976	0.4583

4.3 Token 成本分析

DocRAG 每次问答仅向 VLM 发送检索筛选后的相关页面（通常 3–5 页）和文本证据，而非整个文档。以一篇 60 页 ESG 报告为例：DocRAG 每次输入约 3000–5000 等效 token，而全量上传需 50000–80000 等效 token。图 4.4 直观展示了估算的输入 token 节省比例——DocRAG 相比全量上传可节省约 **94%** 的输入 token。这一优势在多轮对话和批量评测场景下尤为显著。

4.4 错误分析

通过人工审查低分样本，归纳四类主要错误模式：




图 4.4 DocRAG vs 全量上传：估算输入 Token 节省率

1. **检索跨度不足**：FAISS 召回可能仅命中跨页起止页中的一页，continuation 边未将另一端文本引入证据集。
2. **答案格式冗长**：VLM 即使 short 模式也输出大量铺垫，导致与简洁标准答案的 ANLS/EM 偏低。
3. **图表视觉推理脱节**：模型有时仅依赖文本形式的图表描述，忽略页面原图中的视觉细节（趋势线斜率、柱状图相对高度）。
4. **多跳证据链断裂**：multi_hop 问题需在不同节点间建立推理链，当中间节点的语义关系边存在噪声或缺失时，证据链中断。

4.5 实验小结

本章通过五组消融实验验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性：完整系统在全部指标上最优，FAISS 语义召回是最关键的单一组件，图谱和图像提供额外增益，页面级证据定位达 92.5% 召回率。Token 分析表明 DocRAG 相比全量上传可节省约 94% 的输入 token。

5 总结与展望

5.1 主要工作总结

本文设计并实现了一个完整的多模态 GraphRAG 文档问答系统，主要工作包括：

1. **多模态文档解析流水线**：基于 qwen3-vl-8b-instruct 的页面图像结构化抽取，支持七字段 JSON 输出（文本、表格、图表、结论、关键词、实体、关系），含 repair prompt 重试和 text-only 兜底机制。
2. **异构文档知识图谱**：设计了面向文档问答的异构文档图，将 text、table、figure、conclusion、keyword 等组织为节点，通过 same_page、keyword_hit、continuation 等六类边连接，捕获版面结构、跨页延续和图表-文本对应关系。
3. **GraphRAG 多阶段检索与多模态生成**：实现“FAISS 语义召回 → 图谱邻域扩展 → 社区全局补充”的检索策略，将文本证据、关系路径和页面原图融合为多模态 prompt 驱动 VLM 生成可追溯答案。
4. **完整系统原型**：实现 Flask 后端（/ingest、/chat、/graph 等 API）和 vis-network 图谱可视化前端，支持文档上传、交互式问答和证据追溯。
5. **系统性实验评测**：构建 120 题六类型自建测试集，通过五组消融实验验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性，完整系统在全部指标上最优（ANLS 0.084、Token F1 0.619、Heuristic Judge 0.481、Page Recall 0.925）。

5.2 局限性与未来展望

当前系统存在以下局限：VLM 抽取的语义关系边存在噪声，多跳推理链条不够稳定；跨页延续边权重为二值化，缺乏语义连续性强度的精细度量；答案格式控制不足导致 ANLS 偏低；图谱在入库后为静态结构，未根据查询动态调整。未来可从以下方向改进：

1. **动态图谱检索**：借鉴 Query-Driven GraphRAG^[6]，在查询时根据问题动态激活图谱相关区域。
2. **语义级评测**：引入 BERTScore 和 LLM 自动评判，弥补 ANLS/EM 对长答案的评分盲区。
3. **VLM LoRA 微调**：在文档特定任务（表格理解、图表推理、引用格式输出）上微调以提升表现。
4. **幻觉检测与归因**：建立答案断言与检索证据的对应关系，实现细粒度证据归

因。

5. **多文档联合推理**：通过跨文档图谱桥接支持跨文档的比较与综合型问题。

本项目证明了“向量检索 + 异构图谱 + 多模态 VLM”技术路线在文档问答场景中的可行性和有效性，消融实验清晰揭示了各组件的贡献权重，为后续研究提供了定量参考。

参 考 文 献

- [1] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]. Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 9459-9474.
- [2] Edge D, Trinh H, Cheng N, et al. From local to global: A graph RAG approach to query-focused summarization[A]. 2024.
- [3] Qwen Team. Qwen3-VL official repository and Qwen3-VL-8B-Instruct model card[Z]. 2025.
- [4] Johnson J, Douze M, Jégou H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547.
- [5] Microsoft. Microsoft GraphRAG documentation: Query engine overview and indexing overview [Z]. 2025.
- [6] Bu C, Jiang Y, Xu J, et al. Query-driven multimodal GraphRAG: Dynamic local knowledge graph construction for online reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2025.
- [7] Mathew M, Karatzas D, Jawahar C V. DocVQA: A dataset for VQA on document images[C]. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2021: 2200-2209.
- [8] Masry A, Long D X, Tan J Q, et al. ChartQA: A benchmark for question answering about charts with visual and logical reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2022.
- [9] Faysse M, Colombo P, Piccardi T, et al. ColPali: Efficient document retrieval with vision language models[A]. 2024.
- [10] Dong K, Zhao Y, Xu W, et al. Benchmarking retrieval-augmented multimodal generation for document question answering[A]. 2025.
- [11] Liu H, Li C, Wu Q, et al. Visual instruction tuning[C]. Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [12] Zhu D, Chen J, Shen X, et al. MiniGPT-4: Enhancing vision-language understanding with advanced large language models[C]. International Conference on Learning Representations (ICLR). 2024.

致 谢

感谢刘阳老师在课程“多模态大模型原理与应用”中的悉心指导，以及在选题讨论和实验方案优化中提供的宝贵建议。感谢小组成员之间的通力合作：梁力航同学负责系统架构设计与核心链路实现（包括文档解析、向量索引、图谱构建、GraphRAG 问答链、Flask 后端和前端可视化），为项目奠定了坚实的工程基础；李俊璋同学负责评测体系搭建与实验执行（包括评测脚本开发、指标实现、消融实验运行和 Token 成本分析），为实验结果的可靠性和完整性提供了保障；丁子睿同学负责报告撰写与数据分析（包括 LaTeX 报告、消融实验结果分析和答辩材料准备）。三位成员在项目过程中分工明确、协作紧密，充分运用了 Agentic Engineering 的方法论，各自使用 Claude Code 辅助开发并通过 Git Worktree 实现并行协作，最终完成了这一跨模块整合的系统。

还要感谢所有开源社区和研究者，他们开放的模型（Qwen3-VL）、数据集（DocVQA、ChartQA、pdfQA）、框架（LangChain、FAISS、networkx）和研究成果为本项目提供了不可或缺的基础。本项目所有代码已开源于 GitHub，供后续课程同学参考和改进。

2026 年 6 月