



# 本科生毕业论文（设计）

## 题目：文档理解与多模态 GraphRAG 检索问答系统结题报告

姓名 丁子睿、梁力航、李俊璋

学号 23336058、23336128、23336113

院系 计算机学院

专业 计算机科学与技术

指导教师 刘阳

2026 年 6 月 3 日

## 摘 要

传统文本检索增强生成 (RAG) 在处理图文混排、跨页引用和结构复杂的长文档时, 存在视觉信息丢失、结构关系不足和证据链不可解释等问题。本文设计并实现了一个多模态 GraphRAG 文档问答系统, 围绕“FAISS 向量索引 + networkx 异构文档图 + 页面图像 + 视觉语言模型”的技术路线, 实现了从文档入库、结构化解析、向量索引与知识图谱构建到多模态检索与答案生成的完整链路。系统使用 PyMuPDF 渲染 PDF 页面图像, 调用 qwen3-vl-8b-instruct 进行结构化抽取, 将文本、表格、图表、结论、关键词和关系同时写入 FAISS 索引和异构文档图谱; 在问答阶段融合向量语义召回、图谱邻域扩展和社区级全局补充, 最终由 VLM 基于多模态证据生成可追溯引用的答案。

实验方面, 基于 12 篇 ESG 报告构建了 120 道覆盖六种类型 (文本定位、表格问答、图表理解、跨页延续、多跳关系、引用追踪) 的自建测试集, 通过五组消融实验系统评估各组件贡献。结果表明, 完整系统在全部指标上均最优 (ANLS 0.084、Token F1 0.619、Heuristic Judge 0.481、证据页面召回率 0.925), 验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性。消融分析揭示 FAISS 语义召回是最关键的单一组件, 而知识图谱和页面图像对证据定位和视觉推理起到了重要补充作用。

**关键词:** 文档理解, 检索增强生成, GraphRAG, 多模态问答, 视觉语言模型, 知识图谱

## 目 录

|                             |    |
|-----------------------------|----|
| 1 绪论 .....                  | 1  |
| 1.1 研究背景与意义 .....           | 1  |
| 1.2 研究目标与内容 .....           | 2  |
| 1.3 论文组织结构 .....            | 2  |
| 2 相关工作 .....                | 4  |
| 2.1 检索增强生成 (RAG) .....      | 4  |
| 2.2 图增强检索与 GraphRAG .....   | 4  |
| 2.3 多模态文档理解与问答 .....        | 4  |
| 2.4 视觉语言模型 .....            | 5  |
| 3 系统设计与实现 .....             | 6  |
| 3.1 总体架构 .....              | 6  |
| 3.2 文档解析与结构化抽取 .....        | 7  |
| 3.3 知识图谱构建 .....            | 7  |
| 3.4 向量索引与 GraphRAG 检索 ..... | 7  |
| 3.5 后端与前端 .....             | 8  |
| 4 实验设计与结果分析 .....           | 9  |
| 4.1 实验设置 .....              | 9  |
| 4.2 实验结果 .....              | 9  |
| 4.3 Token 成本分析 .....        | 11 |
| 4.4 错误分析 .....              | 11 |
| 4.5 实验小结 .....              | 11 |
| 5 总结与展望 .....               | 12 |
| 5.1 主要工作总结 .....            | 12 |
| 5.2 局限性与未来展望 .....          | 12 |
| 参考文献 .....                  | 14 |
| 致谢 .....                    | 15 |

# 1 绪论

## 1.1 研究背景与意义

随着大语言模型 (Large Language Models, LLMs) 的飞速发展, 其在自然语言理解与生成任务上展现出卓越的能力。然而, 纯参数化的 LLM 面临知识时效性不足、事实性偏差 (幻觉) 以及难以追溯推理依据等问题。检索增强生成 (Retrieval-Augmented Generation, RAG) 技术通过在生成回答前从外部知识库检索相关证据, 将参数化知识与非参数化外部知识相结合, 有效缓解了上述问题<sup>[1]</sup>。RAG 的核心价值在于提升知识密集型任务的事实性、可更新性和证据可追踪性, 已在企业知识问答、学术文献分析、法律文书检索等场景得到广泛应用。

然而, 真实世界中的文档远非纯文本集合。学术论文、企业财报、技术手册、合同文书和教学课件等文档通常同时包含正文、公式、表格、图表、图像、图注、脚注、跨页段落和图表引用等多种信息形态。传统文本 RAG 主要依赖 OCR 或 PDF 文本抽取后的纯文本向量相似度匹配, 在处理这类图文混排的复杂文档时面临三个根本性挑战:

1. **视觉信息丢失**: 图表趋势、版面结构、颜色标记、坐标轴和表格边界等视觉信息很难被纯文本准确保留。许多关键语义 (如折线图的趋势方向、柱状图的对比关系、流程图的步骤先后) 天然依赖视觉表达, 仅靠文本描述难以完整捕捉。
2. **结构关系不足**: 同一页内的图文对应关系、跨页段落的延续关系、图号与结论之间的支撑关系、关键词与内容片段的锚定关系等, 很难仅通过向量相似度稳定表达。真实文档中的重要信息往往不是线性排列, 而是通过复杂的引用关系相互关联。
3. **证据链不可解释**: 向量检索擅长找到与查询语义相似的孤立文本片段, 但不擅长回答“某结论由哪些图表和实验支撑”这类多跳推理问题。用户难以追溯答案的证据来源和推理路径。

GraphRAG 技术通过在传统 RAG 的基础上引入图结构, 为解决上述问题提供了新的思路。GraphRAG 将知识库中的文本片段、实体、概念、关系和事件组织为知识图谱, 使检索不仅依赖语义相似度, 还能沿图谱中的关系边进行多跳扩展<sup>[2]</sup>。对于文档问答而言, 图结构可以将页面、图表、表格、段落、关键词和结论等异质元素统一组织到同一证据空间中, 通过显式的关系边捕获跨页延续、图文支撑和多跳推理路径。

与此同时, 视觉语言模型 (Vision-Language Models, VLMs) 的快速发展为多模

态文档理解提供了强大的技术基础。以 Qwen-VL 系列为代表的视觉语言模型能够直接接收页面图像和文本提示，完成 OCR 识别、版面理解、图表描述、结构化抽取和视觉问答等任务<sup>[3]</sup>。这为构建端到端的多模态文档问答系统提供了便利：不再需要组合 OCR 引擎、版面分析器、表格识别器等多个独立模块，而是由一个统一的 VLM 完成多模态文档理解的各项子任务。

## 1.2 研究目标与内容

本项目面向中山大学 2025–2026 春季学期“多模态大模型原理与应用”课程题目 3“文档理解 + 多模态检索问答系统”，目标是设计并实现一个能够处理 PDF、扫描文档、论文页面和演示文稿截图的多模态 GraphRAG 文档问答系统。

本研究的核心问题是：

对于图文混排、跨页引用和结构复杂的长文档，如何把页面视觉信息、文本语义片段和知识图谱关系融合到同一条检索问答链路中，使回答既能利用多模态证据，又能给出可追溯的页码、节点和关系依据？

围绕这一核心问题，本项目的具体研究内容包括：

1. **多模态文档解析与结构化**：设计基于 VLM 的页面图像结构化抽取流水线，从文档页面中同时提取文本块、表格、图表描述、结论、关键词和语义关系，生成结构化的多模态文档表示。
2. **异构图谱构建**：设计面向文档问答的异构文档图结构，将文本、表格、图表、结论、关键词等内容节点通过同页边、关键词边、跨页延续边和语义关系边组织为统一的知识图谱。
3. **GraphRAG 检索与生成**：设计融合向量检索、图谱邻域扩展和社区级全局补充的多阶段检索策略，以及将文本证据、关系路径和页面图像融合为多模态上下文的答案生成方法。
4. **系统实现与前端可视化**：实现完整的端到端系统原型，包括文档入库、知识库管理、在线问答、图谱可视化等核心功能，提供可交互的 Web 界面。
5. **实验评测与消融分析**：构建自建测试集，设计多组消融实验，系统性评估向量检索、知识图谱和多模态证据各组件对问答性能的贡献。

## 1.3 论文组织结构

本文其余章节的组织如下：

- **第二章相关工作**：系统回顾 RAG、GraphRAG、多模态文档理解和视觉语言模型等领域的研究现状，分析现有工作的优势与不足，明确本项目的技术定

位。

- **第三章系统设计与实现：**详细阐述系统的总体架构、核心模块设计、关键技术实现细节，包括文档解析流水线、图谱构建算法、GraphRAG 检索与生成策略、后端 API 和前端界面。
- **第四章实验设计与结果分析：**介绍自建测试集的构建过程、评测指标设计、消融实验方案，报告并分析五组消融实验的定量结果，讨论不同组件对系统性能的影响。
- **第五章总结与展望：**总结本文的主要工作和贡献，分析系统的局限性，展望未来改进方向。

## 2 相关工作

本章从检索增强生成、图增强检索、多模态文档理解和视觉语言模型四个方面梳理相关研究。

### 2.1 检索增强生成 (RAG)

Lewis 等人在 NeurIPS 2020 提出的 RAG 框架证明了“参数知识 + 非参数知识”的组合方式能显著提升知识密集型 NLP 任务的准确性和可追溯性<sup>[1]</sup>。典型 RAG 流程将文档切分为文本块并存入 FAISS 等向量数据库<sup>[4]</sup>，查询时通过语义相似度检索相关片段交由生成模型作答。然而标准 RAG 将文档处理为独立文本片段，难以处理跨段落、跨页面、多实体关联和证据链推理的复杂问题；在图文混排场景中，PDF 文本抽取或 OCR 阶段还易丢失版面信息、图像语义和表格结构。模块化 RAG 和自反思 RAG 等改进方案主要在文本检索框架内优化，未从根本上解决文档结构关系和多模态信息融合问题。

### 2.2 图增强检索与 GraphRAG

GraphRAG 引入图结构来组织知识，使检索能沿图关系扩展证据。Edge 等人提出的 GraphRAG 框架将文档构造成实体知识图谱并生成社区摘要，同时支持围绕实体的局部搜索 (Local Search) 和基于社区总结的全局搜索 (Global Search)<sup>[2]</sup>。微软官方实现进一步提供了基于 Leiden 算法的层级社区检测和 map-reduce 式全局回答流程<sup>[5]</sup>。Bu 等人在 ACL 2025 提出了 Query-Driven Multimodal GraphRAG，强调根据查询语义动态构建局部图以提升跨模态推理<sup>[6]</sup>。

现有 GraphRAG 工作主要面向大规模文本语料，构建流程计算成本较高，且对文档页面中的图表、表格和视觉布局等多模态信息利用不足。本项目的路线有所不同：直接从页面图像出发，使用 VLM 进行文本/表格/图表/关键词/关系的一体化抽取，构建轻量异构文档图，在查询时综合使用向量检索、图谱邻域扩展和社区补充，是一种更适合课程项目场景的多模态 GraphRAG 实现。

### 2.3 多模态文档理解与问答

DocVQA 数据集包含 12,000 余张文档图像和 50,000 余个问题，要求模型从文档图像中阅读文字、理解版面结构并给出抽取式答案<sup>[7]</sup>。ChartQA 聚焦图表问答，

涉及柱状图、折线图、趋势比较和简单算术推理<sup>[8]</sup>。这些基准揭示了文档问答的关键特征：视觉布局、表格边界、图表形态和图文对应关系本身就是语义的一部分。

在多模态文档检索方面，ColPali 从页面图像直接生成多向量表示并使用 late interaction 检索，表明页面图像本身可作为检索对象<sup>[9]</sup>。MMDocRAG 基准进一步强调长文档 RAG 需要选择并整合文本、表格、图像等多模态证据<sup>[10]</sup>。这些工作启示我们：文档问答系统应保留页面原图、图表描述、bbox 等信息，同时关注证据引用的准确性和完整性。

## 2.4 视觉语言模型

LLaVA、MiniGPT-4 等工作通过视觉指令微调使 VLM 能遵循自然语言指令完成视觉推理<sup>[11-12]</sup>。Qwen3-VL 系列支持图像、视频和文本的统一理解，在 OCR、空间感知、长上下文和多模态推理方面进行了专门强化<sup>[3]</sup>，能在单次推理中同时完成页面文本识别、表格提取、图表理解和结构化 JSON 输出。VLM 的端到端特性使传统文档理解中 OCR、版面分析、表格识别等多模块组合的工程复杂度大幅降低。

综合来看，纯文本 RAG 结构简单但无法处理视觉信息和文档结构关系；文本 GraphRAG 能利用实体和关系做多跳扩展但缺少视觉证据的利用。本项目采用“FAISS + 异构文档图 + 页面图像 + VLM”的技术路线，将 RAG 的可更新性、GraphRAG 的关系扩展能力和 VLM 的视觉理解能力统一到同一条可追溯的文档问答链路中。



### 3 系统设计与实现

#### 3.1 总体架构

系统围绕“知识库构建”和“在线问答”两条链路展开，总体架构如图 3.1 所示。




图 3.1 系统总体架构

知识库构建链路通过 `Flask /ingest` 接口接收文件后，调用 `build_multimodal_graphrag.py` 执行入库：`PyMuPDF` 将 PDF 渲染为页面图像，`qwen3-vl-8b-instruct` 进行结构化抽取得到文本、表格、图表、结论、关键词和关系，封装为 `LangChain Document` 对象。同一批内容被分别写入 `DashScope text-embedding-v3` 生成的 `FAISS` 向量索引和 `networkx` 异构文档图。`FAISS` 索引、图谱和页面原图通过 `node_id`、`page`、`source`、`bbox` 等元数据对齐，形成统一的多模态证据空间。

在线问答链路从 `/chat` 接口进入 `MultiModalGraphRAG.ask()`：`FAISS` 语义召回种子节点 → 图谱邻域扩展与二跳桥接 → 社区 `profile` 全局补充 → 融合文本证据、关系路径与页面原图为多模态 `prompt` → `VLM` 生成可追溯答案。前端提供 `Chat Workspace`、`vis-network` 图谱可视化和 `Node Inspector` 三个核心交互区域。

## 3.2 文档解析与结构化抽取

系统使用 PyMuPDF 将 PDF 页面以 2.0 倍缩放渲染为 PNG，调用 qwen3-vl-8b-instruct 进行七字段结构化抽取：texts（正文/标题/图注，含 bbox）、tables（Markdown 表格）、figures（图表编号/描述/bbox）、section\_conclusions（页面结论）、entities（命名实体）、keywords（方法/模型/指标等关键词）、relations（三元组语义关系）。

解析模块包含三类鲁棒性策略：抽取稀疏时自动使用高召回 repair prompt 重试；仍缺少文本块时调用 text-only prompt 兜底；JSON 解析使用字符串扫描定位对象边界配合 raw\_decode 容错，非法 JSON 时包装为最小化 text-only Document。所有片段被赋予稳定的 node\_id（基于文档哈希、页码和类型），保留完整元数据用于检索、引用和可视化。

## 3.3 知识图谱构建

本系统的图谱是面向文档问答定制设计的**异构文档图**。节点类型包括：内容节点（text、table、figure、conclusion、cross\_page\_text）和关键词节点（以 method/model/dataset/metric/task 等分类前缀组织）。边类型包括：same\_page（同页上下文）、keyword\_hit（关键词与内容锚定）、cooccurrence（同页关键词共现）、continuation（相邻页文本延续）、cross\_page\_merge（跨页合并联系）和 VLM 抽取的语义关系边。

这种设计使图谱不仅能支撑多跳推理，还能捕获版面结构、跨页延续和图表-文本对应关系。系统故意弱化不稳定的实体节点，优先使用关键词和内容锚点作为图骨架。图谱构建后使用 greedy modularity communities 算法进行社区检测，每个社区被表征为包含关键词分布、页面范围和节点统计的轻量 profile，用于问答阶段的全局上下文补充。

## 3.4 向量索引与 GraphRAG 检索

### 3.4.1 向量索引

系统通过 LangChain FAISS 集成和 DashScope text-embedding-v3 构建本地向量索引（支持切换本地 HuggingFace 模型）。每个 Document 的 page\_content 在嵌入前拼接类型标签和页码信息以增强类型感知。FAISS 索引支持增量更新：通过 SHA-256 文件签名检查文档是否已存在于 build\_meta.json 注册表，仅对新文档执行解析和嵌入。

### 3.4.2 多阶段检索与生成

问答链 MultiModalGraphRAG 的检索过程分三阶段：(1) FAISS top-k (默认  $k=3$ ) 语义召回种子节点，支持 `source_hint` 限定文档源；(2) 在文档图中从种子节点执行一跳邻域扩展 (`same_page`、`keyword_hit` 等)，再通过关键词 hub 做二跳桥接，总节点上限 18；(3) 将查询词与社区 profile 匹配，按命中数、重叠度和规模选择全局补充证据。

检索完成后构造五层多模态 prompt：任务指令 → 图谱关系链 → 全局社区证据 → 文本证据块 → 相关页面原图 (base64 data URI)。最终由 `qwen3-vl-8b-instruct` 生成答案，返回 `GraphRAGResult` (含答案、页码、节点 ID、关系路径、图像路径)。系统通过 `use_vectorstore`、`use_graph`、`use_images` 三个布尔标志支持五种消融模式 (`full/vector_only/graph_only/no_image/none`)。

## 3.5 后端与前端

后端基于 Flask 提供 RESTful API: `/ingest` (文件上传入库, 支持 token 鉴权和互斥锁防并发)、`/chat` (问答, 返回答案与引用)、`/graph` (图谱 JSON, gzip 压缩、含节点级元数据)、`/node/<id>` (节点懒加载) 和 `/outputs/<path>` (静态文件访问)。工程优化包括: 图谱 mtime 缓存自动失效、大响应 gzip 压缩和文件名安全清洗。

前端为单页应用 (`web/index.html + web/app.js`)，核心功能包括: Chat Workspace (Markdown 答案渲染、多轮对话)、Knowledge Graph (`vis-network` 交互式图谱, 禁用物理引擎处理 6000+ 节点场景) 和 Node Inspector (节点详情、页面预览和 bbox Canvas 裁剪展示)。

## 4 实验设计与结果分析

本章系统评估多模态 GraphRAG 系统的问答性能，介绍实验设置、消融实验结果和错误分析。

### 4.1 实验设置

#### 4.1.1 数据集

我们从 pdfQA/ClimRetrieve 文档集中选取 12 篇 ESG 可持续发展报告（涵盖 Microsoft、AT&T、AstraZeneca、Boeing、Coca-Cola、Meta、Walmart 等多个行业），构建了包含 **120 道问答对** 的自建测试集，覆盖六种问题类型：文本定位（30 题，25%）、表格问答（27 题，22.5%）、图表理解（17 题，14.2%）、跨页延续（22 题，18.3%）、多跳关系（12 题，10%）和引用追踪（12 题，10%）。每道问题标注了标准答案、问题类型、难度等级和证据页码。

#### 4.1.2 评测指标

1. **ANLS**: DocVQA 官方指标，归一化编辑距离（阈值 0.5）。
  2. **Token F1**: 基于字符 bigram 的 F1 分数，对中文友好。
  3. **Heuristic Judge**: 规则组合评分,  $EM=1.0$ 、 $Containment=0.9$ 、 $Token\ F1 \geq 0.8=0.8$ 、 $Token\ F1 \geq 0.5=0.5$ 、 $Token\ F1 \geq 0.3=0.25$ 、其余 0。
  4. **Evidence Page Recall**: 预测页码与标准证据页码有交集的样本比例。
- 所有指标均经 NFKC 规范化处理，多标准答案取下最大值。

#### 4.1.3 消融方案

五组消融实验设计如下：**full**（FAISS + 图谱 + 图像，完整系统）、**vector\_only**（仅 FAISS + 图像）、**graph\_only**（仅图谱 + 图像）、**no\_image**（FAISS + 图谱，无图像）、**none**（无检索基线）。所有实验使用相同的 120 题和 qwen3-vl-8b-instruct 模型，仅检索配置不同。

### 4.2 实验结果

#### 4.2.1 整体性能

五组消融实验结果如表 4.1 所示。完整系统在所有指标上均取得最优。

表 4.1 五组消融实验整体指标对比

| 指标                   | none   | graph_only | vector_only | no_image | full          |
|----------------------|--------|------------|-------------|----------|---------------|
| ANLS                 | 0.0088 | 0.0044     | 0.0549      | 0.0790   | <b>0.0840</b> |
| Token F1             | 0.1924 | 0.4007     | 0.5704      | 0.6074   | <b>0.6185</b> |
| Heuristic Judge      | 0.1042 | 0.3042     | 0.4408      | 0.4750   | <b>0.4813</b> |
| Evidence Page Recall | 0.0000 | 0.8917     | 0.8750      | 0.9167   | <b>0.9250</b> |

#### 4.2.2 消融分析

(1) **FAISS 向量检索是最关键的组件。** `vector_only` 的 ANLS (0.0549) 是 `graph_only` (0.0044) 的 12.5 倍, Token F1 和 Heuristic Judge 也显著领先。仅有图谱关键词匹配无法提供足够的语义覆盖, FAISS 的稠密语义召回是不可替代的基础。

(2) **图谱扩展提供额外增益。** 对比 full 与 `vector_only`, 引入图谱后 ANLS 提升 53.1% (0.0549 → 0.0840), Token F1 提升 8.4%, Evidence Page Recall 提升 5.7%。图谱邻域扩展增强了语义证据广度, 提升了页面定位准确性。

(3) **页面图像有正向贡献但幅度较小。** 移除图像后 ANLS 下降 6.0%, Token F1 下降 1.8%, 说明当前系统中文档的文本抽取质量较高, 图像主要对图表理解和视觉细节问题发挥作用。

(4) **无检索基线完全失效。** `none` 组的 ANLS 仅为 0.0088, 证据页面召回率为 0, 反衬出检索增强在文档问答中的必要性。

(5) **`graph_only` 的“高召回、低准确”现象值得关注。** `graph_only` 的 Evidence Page Recall (0.8917) 与 `vector_only` (0.8750) 相当, 但 ANLS 仅为 0.0044。图谱可通过关键词找到正确页面, 但从页面提取的文本证据质量不足, 导致模型“看对了地方”却“答不对问题”。

#### 4.2.3 按问题类型分析

表 4.2 展示了完整系统在六种问题类型上的性能分布。`text_location` 和 `table_qa` 表现最好 (ANLS 0.15 和 0.12, Heuristic Judge 约 0.50), 说明 FAISS 检索能准确定位单页内的文本和表格信息。`cross_page` 和 `chart_understanding` 居中 (ANLS 0.02–0.10), 跨页证据合并和图表视觉推理仍有改进空间。`multi_hop` 和 `citation_tracking` 的 ANLS 为零, 但 Token F1 约 0.59, 说明回答语义上存在重叠——零 ANLS 主要因长答案多等价表述导致编辑距离评分失效。

表 4.2 完整系统按问题类型的指标分布

| 问题类型                | 数量 | ANLS          | Token F1      | Heuristic Judge |
|---------------------|----|---------------|---------------|-----------------|
| text_location       | 30 | <b>0.1535</b> | 0.6305        | 0.4767          |
| table_qa            | 27 | 0.1218        | <b>0.6461</b> | <b>0.5019</b>   |
| chart_understanding | 17 | 0.0989        | 0.6102        | 0.4765          |
| cross_page          | 22 | 0.0232        | 0.6018        | 0.4795          |
| multi_hop           | 12 | 0.0000        | 0.5898        | 0.4792          |
| citation_tracking   | 12 | 0.0000        | 0.5976        | 0.4583          |

### 4.3 Token 成本分析

DocRAG 每次问答仅向 VLM 发送检索筛选后的相关页面（通常 3–5 页）和文本证据，而非整个文档。以一篇 60 页 ESG 报告为例：DocRAG 每次输入约 3000–5000 等效 token，而全量上传需 50000–80000 等效 token，估算输入 token 节省率约 **94%**。这一优势在多轮对话和批量评测场景下尤为显著。

### 4.4 错误分析

通过人工审查低分样本，归纳四类主要错误模式：

1. **检索跨度不足**：FAISS 召回可能仅命中跨页起止页中的一页，continuation 边未将另一端文本引入证据集。
2. **答案格式冗长**：VLM 即使 short 模式也输出大量铺垫，导致与简洁标准答案的 ANLS/EM 偏低。
3. **图表视觉推理脱节**：模型有时仅依赖文本形式的图表描述，忽略页面原图中的视觉细节（趋势线斜率、柱状图相对高度）。
4. **多跳证据链断裂**：multi\_hop 问题需在不同节点间建立推理链，当中间节点的语义关系边存在噪声或缺失时，证据链中断。

### 4.5 实验小结

本章通过五组消融实验验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性：完整系统在全部指标上最优，FAISS 语义召回是最关键的单一组件，图谱和图像提供额外增益，页面级证据定位达 92.5% 召回率。Token 分析表明 DocRAG 相比全量上传可节省约 94% 的输入 token。

## 5 总结与展望

### 5.1 主要工作总结

本文设计并实现了一个完整的多模态 GraphRAG 文档问答系统，主要工作包括：

1. **多模态文档解析流水线**：基于 qwen3-vl-8b-instruct 的页面图像结构化抽取，支持七字段 JSON 输出（文本、表格、图表、结论、关键词、实体、关系），含 repair prompt 重试和 text-only 兜底机制。
2. **异构文档知识图谱**：设计了面向文档问答的异构文档图，将 text、table、figure、conclusion、keyword 等组织为节点，通过 same\_page、keyword\_hit、continuation 等六类边连接，捕获版面结构、跨页延续和图表-文本对应关系。
3. **GraphRAG 多阶段检索与多模态生成**：实现“FAISS 语义召回 → 图谱邻域扩展 → 社区全局补充”的检索策略，将文本证据、关系路径和页面原图融合为多模态 prompt 驱动 VLM 生成可追溯答案。
4. **完整系统原型**：实现 Flask 后端（/ingest、/chat、/graph 等 API）和 vis-network 图谱可视化前端，支持文档上传、交互式问答和证据追溯。
5. **系统性实验评测**：构建 120 题六类型自建测试集，通过五组消融实验验证了“向量检索 + 图谱扩展 + 多模态融合”路线的有效性，完整系统在全部指标上最优（ANLS 0.084、Token F1 0.619、Heuristic Judge 0.481、Page Recall 0.925）。

### 5.2 局限性与未来展望

当前系统存在以下局限：VLM 抽取的语义关系边存在噪声，多跳推理链条不够稳定；跨页延续边权重为二值化，缺乏语义连续性强度的精细度量；答案格式控制不足导致 ANLS 偏低；图谱在入库后为静态结构，未根据查询动态调整。未来可从以下方向改进：

1. **动态图谱检索**：借鉴 Query-Driven GraphRAG<sup>[6]</sup>，在查询时根据问题动态激活图谱相关区域。
2. **语义级评测**：引入 BERTScore 和 LLM 自动评判，弥补 ANLS/EM 对长答案的评分盲区。
3. **VLM LoRA 微调**：在文档特定任务（表格理解、图表推理、引用格式输出）上微调以提升表现。
4. **幻觉检测与归因**：建立答案断言与检索证据的对应关系，实现细粒度证据归

因。

5. **多文档联合推理**：通过跨文档图谱桥接支持跨文档的比较与综合型问题。

本项目证明了“向量检索 + 异构图谱 + 多模态 VLM”技术路线在文档问答场景中的可行性和有效性，消融实验清晰揭示了各组件的贡献权重，为后续研究提供了定量参考。



## 参 考 文 献

- [1] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]. Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 9459-9474.
- [2] Edge D, Trinh H, Cheng N, et al. From local to global: A graph RAG approach to query-focused summarization[A]. 2024.
- [3] Qwen Team. Qwen3-VL official repository and Qwen3-VL-8B-Instruct model card[Z]. 2025.
- [4] Johnson J, Douze M, Jégou H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547.
- [5] Microsoft. Microsoft GraphRAG documentation: Query engine overview and indexing overview [Z]. 2025.
- [6] Bu C, Jiang Y, Xu J, et al. Query-driven multimodal GraphRAG: Dynamic local knowledge graph construction for online reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2025.
- [7] Mathew M, Karatzas D, Jawahar C V. DocVQA: A dataset for VQA on document images[C]. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2021: 2200-2209.
- [8] Masry A, Long D X, Tan J Q, et al. ChartQA: A benchmark for question answering about charts with visual and logical reasoning[C]. Findings of the Association for Computational Linguistics (ACL). 2022.
- [9] Faysse M, Colombo P, Piccardi T, et al. ColPali: Efficient document retrieval with vision language models[A]. 2024.
- [10] Dong K, Zhao Y, Xu W, et al. Benchmarking retrieval-augmented multimodal generation for document question answering[A]. 2025.
- [11] Liu H, Li C, Wu Q, et al. Visual instruction tuning[C]. Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [12] Zhu D, Chen J, Shen X, et al. MiniGPT-4: Enhancing vision-language understanding with advanced large language models[C]. International Conference on Learning Representations (ICLR). 2024.

## 致 谢

感谢刘阳老师在课程“多模态大模型原理与应用”中的悉心指导，以及在选题讨论和实验方案优化中提供的宝贵建议。感谢小组成员之间的通力合作：梁力航同学负责系统架构设计与核心链路实现（包括文档解析、向量索引、图谱构建、GraphRAG 问答链、Flask 后端和前端可视化），为项目奠定了坚实的工程基础；李俊璋同学负责评测体系搭建与实验执行（包括评测脚本开发、指标实现、消融实验运行和 Token 成本分析），为实验结果的可靠性和完整性提供了保障；丁子睿同学负责报告撰写与数据分析（包括 LaTeX 报告、消融实验结果分析和答辩材料准备）。三位成员在项目过程中分工明确、协作紧密，充分运用了 Agentic Engineering 的方法论，各自使用 Claude Code 辅助开发并通过 Git Worktree 实现并行协作，最终完成了这一跨模块整合的系统。

还要感谢所有开源社区和研究者，他们开放的模型（Qwen3-VL）、数据集（DocVQA、ChartQA、pdfQA）、框架（LangChain、FAISS、networkx）和研究成果为本项目提供了不可或缺的基础。本项目所有代码已开源于 GitHub，供后续课程同学参考和改进。

2026 年 6 月